DataMaturity: Casos de Insucesso e Aprendizados

Por Que Projetos de Dados Falham e Como Evitar

Índice

1. A Realidade dos Projetos de IA
2. Falha 1: O Modelo Órfão
3. Falha 2: O Pântano de Dados
4. Falha 3: A Caixa Preta

A Realidade dos Projetos de IA

Estudos da indústria mostram que mais de 60% dos modelos de machine learning nunca chegam à produção. Entender os padrões de falha é o primeiro passo para construir uma estratégia de dados resiliente.

Falha 1: O Modelo Órfão

O Cenário: A equipe de ciência de dados constrói um modelo preditivo altamente preciso, mas a área de negócios nunca o utiliza. **A Causa:** Falta de envolvimento do negócio durante o desenvolvimento. O modelo resolveu um problema que os usuários não consideravam prioritário, ou não foi integrado ao fluxo de trabalho (workflow) existente. **A Solução:** Adotar o papel do “Analytics Translator”. Nunca iniciar um projeto sem um patrocinador de negócios e um plano claro de operacionalização.

Falha 2: O Pântano de Dados (Data Swamp)

O Cenário: A empresa investe milhões em um Data Lake, mas os analistas não conseguem encontrar nada útil e não confiam nos dados. **A Causa:** Ingestão de dados sem governança, sem catálogo e sem padronização. O Data Lake virou um repositório de lixo digital. **A Solução:** Implementar governança “by design”. Exigir dicionários de dados, linhagem e verificações de qualidade antes de mover dados para as zonas de consumo.

Falha 3: A Caixa Preta

O Cenário: Um algoritmo de precificação dinâmica sugere preços absurdos e a equipe de vendas desliga o sistema, voltando ao Excel. **A Causa:** Falta de explicabilidade. Os usuários não entendem *por que* o modelo tomou aquela decisão e, portanto, não confiam nele. **A Solução:** Priorizar a interpretabilidade sobre a precisão absoluta em casos de uso sensíveis. Treinar os usuários sobre os limites do modelo e implementar “human-in-the-loop” para exceções.